

Fatores determinantes no valor de Airbnbs em cidades europeias

1st Giovanna Marques Mafra
Centro de Informática - UFPE
Recife, Brazil
gmm8@cin.ufpe.br

2nd Luma Rios Ferreira
Centro de Informática - UFPE
Recife, Brazil
lrf2@cin.ufpe.br

3rd Mariana Sousa Freire
Centro de Informática - UFPE
Recife, Brazil
msf6@cin.ufpe.br

Abstract—Este trabalho investiga os fatores determinantes da formação de preços de acomodações do Airbnb nas cidades de Barcelona e Londres. Foram avaliados modelos de Regressão Linear, KNN e XGBoost, considerando diferentes recortes de dados e estratégias de treinamento. Os resultados indicam que o XGBoost apresentou o melhor desempenho preditivo, evidenciando que o tipo de acomodação, em especial quartos privativos, e a localização do imóvel são os principais determinantes dos preços, enquanto as diferenças entre dias úteis e finais de semana tiveram impacto limitado nos resultados.

I. INTRODUÇÃO

O Airbnb é uma empresa que oferece serviço online de anúncio e reserva de acomodações que provocou uma revolução da cultura de hospedagem no mundo inteiro. Atualmente, gradativamente mais turistas abdicam os tradicionais hotéis e pousadas, em vantagem do melhor custo benefício dos *Airbnbs*, como são popularmente chamados os imóveis ofertados na plataforma.

Dentre os variados desafios de planejar uma viagem, procurar um local adequado para passar um curto período de tempo pode ser problemático, em decorrência da ânsia de equilibrar os desejos particulares com o melhor custo possível. Uma família que deseja explorar o centro histórico, por exemplo, não estaria suscetível a alugar um imóvel com poucos quartos na periferia da cidade.

No mercado europeu, o Airbnb obteve grande sucesso nos aluguéis por temporada devido às populares atrações turísticas do continente. Neste trabalho, focamos particularmente na cidade de Londres, líder em número de imóveis listados para aluguel na plataforma, e na cidade de Barcelona, um tradicional destino de viagem para visitantes de todo o globo.

As autoras procuram, portanto, analisar os fatores determinantes no preço de aluguéis de *Airbnbs* em Londres e em Barcelona, com fim de auxiliar turistas na procura por acomodações a curto prazo com o melhor custo-benefício.

II. ANÁLISE DE DADOS E FEATURE ENGINEERING

Nesta seção, apresenta-se a análise do conjunto de dados utilizado, detalhando suas características estruturais, distribucionais e relacionais. Em seguida, demonstram-se as justificativas para a engenharia de *features* feita na etapa de processamento de dados, assim como o método utilizado de divisão do conjunto em treinamento, validação e teste.

A. Análise Exploratória dos Dados

O conjunto de dados utilizado nesse projeto [1] foi obtido através da raspagem de dados com a ajuda de uma ferramenta de automatização web [3].

Para fins deste trabalho, foram utilizados apenas os dados referentes à cidade de Barcelona e Londres, estes que possuem cada um dois subconjuntos de dados, um referente aos dias úteis da semana (Terça-feira a Quinta-feira) e outro referente aos finais de semana (Sexta-feira a Domingo).

Portanto, a análise presente nesta seção trata de quatro conjuntos de dados diferentes, mas que possuem os mesmos atributos. Para fins de simplificação, denomina-se o conjunto pertinente a Barcelona durante os dias úteis de **B1** e durante os fins de semana de **B2**, enquanto o de Londres durante os dias úteis será referido como **L1** e durante os fins de semana como **L2**.

TABLE I
LISTAGEM DE ATRIBUTOS

Nome	Descrição
Unnamed: 0	Índice da amostra
realSum	Preço completo
room type	Tipo de acomodação
room shared	Se o quarto é compartilhado ou não
room private	Se o quarto é privado ou não
person capacity	Capacidade máxima de hóspedes
host is superhost	Status de <i>superhost</i>
multi	Se o <i>host</i> possui 2-4 anúncios
biz	Se o <i>host</i> possui mais de 4 anúncios
cleanliness rating	Valor de avaliação de limpeza
guest satisfaction overall	Valor de satisfação dos hóspedes
bedrooms	Número de quartos
dist	Distância para o centro da cidade
metro dist	Distância para a estação de metrô mais próxima
attr index	Índice de atratividade da localização
attr index norm	Índice de atratividade normalizada
rest index	Índice de restaurantes da localização
rest index norm	Índice de restaurantes normalizado
lng	Longitude do local
lat	Latitude do local

1) *Análise Exploratória Estrutural*: Os quatro conjuntos de dados possuem a mesma estrutura, com 20 atributos, diferindo apenas no número de amostras: **B1** (1555), **B2** (1278), **L1** (4614) e **L2** (5379). O atributo alvo (*realSum*) representa o preço total, em euros, para duas pessoas em duas noites, enquanto a variável *superhost* identifica anfitriões com elevado padrão de hospitalidade segundo o Airbnb.

TABLE II
TIPOS DE DADOS DOS ATRIBUTOS

Tipo de dados	Atributos
Númerico (int64)	'Unnamed: 0', 'bedrooms'
Númerico (float64)	'realSum', 'person capacity', 'cleanliness rating', 'guest satisfaction overall', 'dist', 'metro dist', 'attr index', 'attr index norm', 'rest index', 'rest index norm', 'lng', 'lat'
Catégorico (object)	'room type'
Catégorico (boolean)	'room private', 'room shared', 'host is superhost', 'multi', 'biz'

As estatísticas descritivas do preço, apresentadas na Tabela III, indicam comportamentos semelhantes entre conjuntos da mesma cidade, sugerindo padrões de precificação consistentes. Os atributos estruturais dos imóveis exibem médias próximas e baixos desvios-padrão em todos os grupos (Tabelas VII e VIII do Material Suplementar), indicando baixa variabilidade. As métricas de satisfação e limpeza apresentam médias elevadas, embora com maior dispersão quando comparadas aos atributos físicos.

TABLE III
ESTATÍSTICAS DESCRITIVAS DO PREÇO

Dataset	Média	DP	Máx	Mín
B1	293.75	321.18	6943.70	69.58
B2	300.28	393.20	6942.77	80.99
L1	360.23	507.78	15,499.90	64.67
L2	362.47	437.74	12,937.27	54.32

As estatísticas descritivas dos atributos numéricos estão demonstradas na tabela VII, correspondente a atributos não relacionados a localização, e na tabela VIII, que refere-se às colunas relacionadas à localização. A partir desse contexto, pode-se inferir que os atributos estruturais do imóveis (como número de quartos e capacidade de pessoas) apresentam médias semelhantes entre os grupos analisados, com baixos desvios-padrão, indicando pouca variabilidade e um padrão relativamente homogêneo entre os conjuntos **B1**, **B2**, **L1** e **L2**. Em relação à satisfação dos hóspedes e à limpeza, observa-se que as médias são elevadas em todos os grupos, sugerindo uma avaliação geral positiva dos anúncios, embora os desvios-padrão da satisfação indiquem maior dispersão das avaliações dos usuário quando comparados aos atributos físicos do imóvel.

Por outro lado, os atributos relacionados à localização, expostos na VIII, apresentam diferenças mais expressivas entre os grupos, especialmene no que se refere à distância ao centro

(*dist*), à proximidade de estações de metrô (*metro dist*) e aos índices de atratividade e restaurantes (*att index*). Os grupos **L1** e **L2** apresentam maiores distâncias médias e menores índices de atratividade, enquanto **B1** e **B2** concentram-se em regiões mais centrais e com maior oferta de pontos de interesse, confirmando que a localização é um fator discriminante relevante.

Na tabela IV, por sua vez, têm-se as estatísticas das variáveis categóricas, nas quais é possível observar que o tipo de acomodação predominante em todos os cenários analisados é o quarto privado (*room private*), especialmente nos conjuntos **B2** e **L1**, nos quais essa categoria ultrapassa 50% e 65%, respectivamente. Isso indica uma preferência por opções que equilibram custo e privacidade, independente da cidade ou do período analisado. Quanto à categoria *entire home*, apresenta maior representatividade em Londres, principalmente no conjunto **L2**, sugerindo que maior demanda ou disponibilidade de acomodações completas, possivelmente associada a viagens de lazer e estadias em grupo.

TABLE IV
ESTATÍSTICAS DESCRITIVAS DE ATRIBUTOS CATEGÓRICOS
(% DE Airbnbs)

	room type			profissionalismo			superhost	
	room shared	room private	entire home	single	multi	biz	sim	não
B1	0.51	76.20	23.27	27.26	37.68	35.04	18.07	81.92
B2	0.31	85.60	14.08	30.98	39.51	29.49	18.23	81.76
L1	0.49	56.89	42.60	30.77	26.93	42.28	14.69	85.30
L2	0.50	54.54	44.95	36.23	27.97	35.78	16.63	83.36

No que se refere ao perfil dos anfitriões, nota-se uma distribuição relativamente equilibrada entre as categorias *single*, *multi* e *biz*, com leve predominância de anfitriões do tipo *multi* em todos os conjuntos. Tal comportamento sugere a presença significativa de anfitriões que gerenciam múltiplos anúncios, o que pode influenciar diretamente em aspectos como padronização do serviço e estratégias de precificação.

Por fim, a maioria dos anúncios pertence a anfitriões que não possuem esse selo *superhost*, embora **L1** e **L2** apresentem percentuais mais elevados de *superhosts* quando comparado a **B1** e **B2**, possivelmente refletindo diferenças no grau de maturidade de mercado entre as cidades.

Nas figuras 6, 7, 8 e 9, disponibilizadas no Material Suplementar, apresenta-se a quantidade de valores únicos das colunas, com o eixo Y em uma escala logarítmica, a fim de esclarecer as diferenças na cardinalidade das variáveis ao longo de várias ordem de magnitude. Os atributos categóricos e booleanos *host_is_superhost*, *room_shared*, *room_private*, *room_type*, *multi* e *biz* não foram inclusos nas imagens por terem apenas dois valores únicos, com exceção de *room_type* que possui três valores únicos.

A análise dessas visualizações indica que os conjuntos referentes à cidade de Barcelona (Figuras 8 e 9 do Material Suplementar) apresentam comportamento semelhante quanto à cardinalidade das variáveis, sem diferenças significativas entre as listagens de dias úteis e de finais de semana. Já as Figuras 6 e 7 demonstram que os conjuntos **L1** e **L2**, ambos referentes

à cidade de Londres, também apresentam similaridades nas magnitudes de suas variáveis.

2) *Análise de Valores Faltantes e Outliers*: Como os datasets foram obtidos para fins de treinamento de modelos de aprendizagem de máquina em outro trabalho, não existem valores faltantes em nenhum dos conjuntos. A análise de *outliers* foi realizada por meio de gráficos *box plot*, utilizando o critério do IQR (Intervalo Interquartil), definido pela diferença entre o terceiro e o primeiro quartil. Os limites (“bigodes”) estendem-se até 1,5 vezes o IQR, permitindo identificar valores discrepantes. A avaliação considerou a variável-alvo (*realSum*) e as variáveis explicatórias, com o objetivo de verificar se valores extremos no alvo estão associados a extremos nas *features*, distinguindo ruído de *outliers*.

As Figuras 1 e 2 apresentam os box plots dos conjuntos **B1**, **B2**, **L1** e **L2**. Em todos os conjuntos, observa-se a presença de pontos fora dos limites dos bigodes, indicando a existência de valores discrepantes segundo o critério do IQR. No entanto, esses valores aparecem de forma pontual e esse comportamento indica a existência de anúncios com preços significativamente mais elevados do que a mediana, os quais se manifestam como outliers nos gráficos.

Ao avaliar as variáveis explicatórias, observa-se que atributos estruturais como número de quartos (*bedrooms*) e capacidade de pessoas (*person_capacity*), apresentam menor dispersão e poucos valores discrepantes, sugerindo maior estabilidade. Em contrapartida, variáveis relacionadas à localização, como distância do centro (*dist*), distância ao metrô (*metro dist*) e índices de atratividade e restaurantes (*attr index*), exibem maior variabilidade e maior quantidade de valores extremos, especialmente no conjunto **L1** e **L2**.

Assim, os *outliers* observados não indicam inconsistências, mas variações reais associadas a características locais e estruturais específicas dos imóveis analisados.

3) *Análise Univariada*: A análise univariada a seguir tem por objetivo compreender o comportamento individual de cada variável dos conjuntos de dados, identificando sua distribuição, tendência central e provendo contexto suficiente para decisões posteriores de seleção e extração de *features*.

As figuras 23, 25, 27 e 29 dizem respeito às análises de cada variável numérica em relação à variável-alvo nos datasets **B1**, **B2**, **L1** e **L2**, respectivamente. Os atributos categóricos, por sua vez, estão expostos nas imagens 24 para **B1**, 26 para **B2**, 28 para **L1** e 30 para **L2**. Todas essas figuras podem ser encontradas no Material Suplementar.

Já a análise individual da distribuição do preço através dos conjuntos de dados está descrita nas figuras 19 para **B1**, 20 para **B2**, 21 para **L1** e 22, localizadas no Material Suplementar.

Ao avaliar *realSum* individualmente, é possível observar que a variável-alvo apresenta assimetria à direita em todos os conjuntos analisados, com concentração da maior parte dos valores em faixas mais baixas e presença de diversos valores extremos superiores.

Para fins de avaliação, utilizamos o coeficiente de correlação de *Pearson*, que indica a relação linear entre duas variáveis, e o valor-p, que indica a significância de tal correlação.

Dentre as *features* numéricas analisadas, em todos os datasets pode-se perceber um padrão de níveis de correlações positivas fracas, na faixa de 0.20 a 0.38, mas com *p-values* baixos ou iguais a 0. Exemplos de tais atributos são *bedrooms* e *person_capacity*.

Em comparação, os datasets que referenciam cidades diferentes exibem estatísticas diferentes em variáveis importantes, como *attr_index*, que representa o índice de atratividade da localização do alojamento. Nos datasets **B1** e **B2**, a variável apresenta correlação fraca, ligeiramente positiva, com valor *p* baixo nos dias úteis e alto nos finais de semana, indicando que clientes podem esperar maiores valores em locais com muitas atrações durante os dias de semana em Barcelona. Enquanto em **L1** e **L2**, há um aumento da correlação e uma diminuição do *p-value*, o que assignala um aumento no preço em locais de índice de atratividade alta independente dos aspectos temporal.

Para as variáveis categóricas, consistentemente a coluna *room_type* aparece como a de menor *p-value* em todos os datasets, com exceção do conjunto **B2**. As autoras argumentam que por **B2** ser o menor conjunto, há a possibilidade da distorção do valor de *p*, mesmo a variável possuindo, na prática, a mesma significância do que no outro dataset que compartilha a mesma cidade.

4) *Análise Bivariada*: A análise bivariada foi realizada por meio da matriz de correlação de *Pearson*, apresentada nas Figuras 3 e 4, considerando conjuntamente observações de dias úteis e finais de semana de Barcelona e Londres. A matriz de correlação evidencia a presença de relações lineares fortes entre *features*. As autoras admitiram que coeficientes com módulo superior a 0,5 indicam potenciais redundâncias entre as variáveis.

Ao analisar as correlações entre as variáveis explicatórias, observa-se que alguns atributos apresentam associações lineares fortes. Destaca-se a correlação positiva entre *person_capacity* e *bedrooms*, o que sugere que anúncios com maior número de quartos tendem a comportar um maior número de pessoas.

Observa-se, também, forte correlação positiva entre *cleanliness_rating* e *guest_satisfaction_overall*, apontando que a avaliação geral dos hóspedes está fortemente associada à percepção de limpeza do imóvel. A sobreposição dessas *features* reflete a qualidade da experiência do usuário.

Nas colunas locais, nota-se uma forte correlação negativa entre a distância ao centro *dist* e os índices de atratividade e restaurantes *attr_index* e *rest_index*. Logo, regiões mais centrais tendem a concentrar maior oferta de serviços e pontos de interesse do que áreas afastadas.

Vale ressaltar que os índices de atratividade *attr_index* e restaurantes *rest_index* e suas versões normalizadas, *attr_index_norm* e *rest_index_norm* possuem coeficientes se aproximam de 1, ou seja, uma correlação quase perfeita. Isso evidencia que essas variáveis carregam essencialmente a mesma informação.

5) *Análise Multivariada*: Com o intuito de aprofundar a compreensão das relações entre as variáveis associadas às satisfação dos usuários, foi aplicada a análise de grupos de




Fig. 1. Box Plot Conjunto B1 e B2




Fig. 2. Box Plot Conjunto L1 e L2




Fig. 3. Matriz de Correlação Barcelona




Fig. 4. Matriz de Correlação Londres

interesse, aliada a visualizações multivariadas e ao uso de variáveis derivadas. Essa abordagem possibilita a identificação de padrões específicos em subconjuntos dos dados, que não seriam evidentes em análises globais. Os resultados para os grupos B1, B2, L1 e L2 são apresentados nas Figuras 12 a 15 que estão no Material Suplementar.

Inicialmente, foi avaliado a interação entre o tipo de quarto e o status de superhost para a satisfação. É possível interpretar que os anúncios administrados por superhosts apresentam

maiores níveis médios de satisfação, independente do tipo de quarto para todos os conjuntos. Esse resultado sugere que o status do superhost é um fator relevante para os clientes pois é associado a atributos como qualidade do atendimento, confiabilidade e experiência na estadia.

Em seguida, foi considerada a satisfação entre faixa de preço e tipo de quarto, evidenciando que a satisfação não cresce estritamente linear com o aumento do preço. Em B1 e B2, constata-se uma maior sensibilidade ao preço, com quedas ou

estagnação da satisfação em faixas mais elevadas, especialmente para determinados tipos de quartos. Em contraste, os grupos **L1** e **L2** apresentam comportamento mais estável ao longo das faixas de preço. Além disso, os tipos de quarto respondem de forma distinta às variações de preço em cada grupo, evidenciando interações entre variáveis categóricas relevantes para a modelagem.

A análise da capacidade do imóvel revelou um padrão recorrente nos grupos de interesse analisados: imóveis de menor capacidade tendem a apresentar maiores médias de satisfação. Como ilustrado na Figura referente ao grupo **B1**, observa-se um comportamento distinto dos demais: a satisfação média aumenta com a capacidade do imóvel, apresentando tendência crescente. Esse padrão contrasta com **B2**, **L1** e **L2**, nos quais há maior variabilidade e indícios de efeitos não lineares, especialmente em capacidades intermediárias. As autoras especulam que, em **B1**, esse resultado pode estar associado a estadias mais funcionais, nas quais imóveis maiores oferecem melhor adequação às necessidades dos usuários durante a semana.

B. Pré-processamento dos dados

A seguir, descrevem-se os passos executados durante o pré-processamento de dados.

1) *Tratamento de Valores Faltantes*: Como nos *datasets* trabalhados neste projeto não possuem valores faltantes, não foi necessário o seu tratamento.

2) *Tratamento de Outliers*: Foi exposto anteriormente o comportamento de *outliers* dos *datasets*. A partir dessa análise, as autoras identificaram uma porcentagem de valores discrepantes não significantes, que referiam-se a casos raros em que os preços eram extremos. A fim de amenizar o impacto da magnitude de algumas variáveis, a coluna alvo, *realSum*, e a coluna de *attr_index*, foram transformadas aplicando o logaritmo de base 10 a seus valores.

3) *Deteção e Tratamento de Duplicadas*: A biblioteca *Pandas* permitiu a deteção de duplicatas de forma fácil e rápida. Com ela, percebeu-se que não haviam dados duplicados dentre os conjuntos de dados presentes neste trabalho. Por conseguinte, não houve tratamento de duplicadas.

4) *Feature Scaling*: A fim de garantir um treinamento seguro, principalmente em decorrência dos algoritmos escolhidos, foi realizada a normalização das variáveis utilizando a ferramenta de *MinMaxScaler*.

O *MinMaxScaler* reescala cada coluna dos conjuntos de dados individualmente e será essencial para o desempenho dos modelos treinados posteriormente.

5) *Encoding de Variáveis Categóricas*: A única variável categórica do tipo *object* é a coluna *room_type*.

Por ser apenas um atributo só possuir três valores únicos, a técnica de encoding escolhida foi a *One-Hot Encoding*, que cria uma nova coluna para cada valor da variável. As novas colunas são *room_type private room* e *room_type shared room*, com a categoria *Entire Home/Apartment* sendo a *baseline* do encoding.

C. Divisão dos Dados

A divisão dos dados entre treinamento e teste foi feita com 80% do conjunto sendo reservado para o treinamento e, consequentemente, 20% foi reservado para o treino. A motivação de tal particionamento é a pequena quantidade de amostras, especialmente no conjunto de dados de Barcelona, que também motivou as autoras a utilizar a técnica da validação cruzada.

A Validação Cruzada *K-Fold* é uma técnica que divide o conjunto de treinamento em K subconjuntos iguais para avaliar o desempenho do modelo de forma mais confiável e minimizar *overfitting*.

D. Feature Engineering

A partir da análise exploratória feita em seções anteriores, algumas colunas foram excluídas dos conjunto de dados.

São estas: *'Unnamed: 0'*, por representar o índice de cada amostra e não ter real impacto no atributo-alvo; *rest_index*, por seu alto índice de correlação com a coluna *attr_index*, que foi mantida; *room_shared* e *room_private*, ambas por representarem informações redundantes que já estão presentes em *room_type*; *attr_index_norm* e *rest_index_norm*, por serem versões normalizadas de outras colunas, foi preferido realizar a normalização nas variáveis originais para garantir a consistência entre todas as colunas; *lat* e *lng*, por apresentarem correlação baixa e não significativa na variável-alvo.

Em contrapartida, também adicionamos a *feature day*, uma variável *dummy* binária que representa as listagens de dias úteis (*day* = 0) e de finais de semana (*day* = 1).

III. MODELAGEM

Nesta seção, serão apresentados os algoritmos de aprendizagem de máquina utilizados para a predição de preços de *Airbnbs* em Barcelona e Londres. As tecnologias utilizadas para a implementação foram a linguagem de programação *Python*, o ambiente de desenvolvimento *Jupyter*, assim como bibliotecas como *"Scikit-learn"* e *Pandas*.

A. Regressão Linear

1) *Conceitos Básicos*: O modelo de regressão linear tem por fundamento o instrumento estatístico de mesmo nome que tem objetivo de resumir dados e possui sensibilidade quanto à variáveis dependentes estatisticamente. A ideia, por seguinte, é estimar a inclinação da uma reta descrita por $y = ax + b$, em que y seria a variável-alvo, ou seja, o preço de uma acomodação, e x seria a representação dos atributos explicativos, chamados regressores.

2) *Justificativa*: A escolha de Regressão Linear como o primeiro modelo a ser treinado foi feita em decorrência da simplicidade, interpretabilidade e eficiência do modelo. Como os conjuntos de dados neste trabalho não possuem uma alta dimensionalidade, os resultados da regressão linear serve de *baseline* para o problema, permitindo comparações com modelos mais complexos.

3) *Espaço de Busca*: O espaço de busca foi definido para avaliar diferentes configurações de regressão linear, variando os parâmetros de regularização e os métodos de otimização. Foram avaliadas versões com e sem regularização, de modo a controlar overfitting e lidar com multicolinearidade.

A fim de controlar a magnitude dos coeficientes, utilizamos a regularização de Ridge. Para o valor de alfa, isto é, o hiperparâmetro que controla a força da penalidade da regularização L2, procuramos em 100 valores igualmente espaçados numa escala logarítmica, começando de -4 e indo até 4. Já para o *solver* da regressão Ridge, a busca foi feita entre *auto*, que seleciona o *solver* automaticamente com base nos dados, e *svd*, um *solver* que utiliza decomposição em valores singulares para calcular os coeficientes.

A busca foi feita utilizando *Grid Search*, já que a regressão linear, mesmo com regularização, tem poucos hiperparâmetros para serem testados. Também utiliza-se a validação cruzada, com a ajuda do *K Fold*, a fim de acrescentar robustez ao modelo.

4) *Hiperparâmetros Seleccionados*: Os hiperparâmetros foram definidos com base na configuração que apresentou melhor desempenho médio na validação cruzada. Como foram realizados múltiplos experimentos, os melhores hiperparâmetros para cada experimento serão descritos posteriormente na seção de análise e comparação de resultados.

B. XGradient Boost

1) *Conceitos Básicos*: XGBoost, sigla para *Extreme Gradient Boosting*, é um modelo baseado em árvores que é altamente eficiente e flexível. Ele combina várias árvores de decisões "fracas" para formar um modelo preditivo forte, otimizando a função de perda de forma incremental.

2) *Justificativa*: As autoras escolheram o algoritmo por sua robustez a outliers, capacidade de lidar com diferentes magnitudes das variáveis e incorporação de regularização explícita, reduzindo o *overfitting*, além de ser um método moderno, amplamente utilizado em competições de ciência de dados, o que comprova sua eficiência e flexibilidade.

3) *Espaço de Busca*: A seleção de hiperparâmetros foi realizada por meio de otimização Bayesiana, utilizando o método *BayesSearchCV*, que permite uma busca mais eficiente no espaço de parâmetros em comparação a métodos exaustivos. Foram avaliados hiperparâmetros de complexidade, aprendizado, amostragem e regularização do modelo, com seleção realizada por validação cruzada em 5 *folds*, utilizando o erro quadrático médio como métrica.

4) *Hiperparâmetros Seleccionados*: Os hiperparâmetros finais foram definidos com base na configuração que apresentou o melhor desempenho médio na validação cruzada. O modelo resultante corresponde ao estimador retornado pela otimização Bayesiana, sendo utilizado no treinamento final do modelo.

C. KNN Regression

1) *Conceitos Básicos*: K-Vizinhos mais próximos é um algoritmo de aprendizagem de máquina baseado em distância, ou seja, ele encontra os K pontos de dados mais próximos da amostra de entrada e retorna a média entre seus valores-alvos.

2) *Justificativa*: A escolha do *KNN Regression* se deu principalmente por sua simplicidade conceitual, rapidez de execução e eficiência computacional, considerando que o conjunto de dados utilizado possui baixa dimensionalidade. O modelo permite capturar padrões locais e relações potencialmente não linearizadas, funcionando como um contraponto à regressão linear e como um modelo complementar para comparação com abordagens mais complexas, como o *XGradient Boost*.

3) *Espaço de Busca*: A seleção dos hiperparâmetros foi realizada por meio do *Grid Search*, tornando viável uma busca exaustiva no espaço de parâmetros. As autoras avaliaram diferentes configurações relacionadas ao número de vizinhos, método de ponderação dos vizinhos e métricas de distância, empregando o coeficiente de determinação como métrica de desempenho.

4) *Hiperparâmetros Seleccionados*: Os hiperparâmetros finais do *KNN Regression* foram definidos com base na configuração que apresentou o melhor desempenho médio durante a validação cruzada.

IV. ANÁLISE E COMPARAÇÃO DE RESULTADOS

Nesta seção listam-se os experimentos feitos a partir dos modelos previamente citados, com o objetivo de identificar quais os fatores determinantes dos preços de AirBnBs. Desse modo, após a demonstração dos resultados, a comparação entre diferentes modelos sobre diferentes conjuntos de dados trarão informações pertinentes para os usuários da plataforma de hospedagem.

Para primeira análise, as autoras optam por juntar os *datasets B1* e *B2* em um único, dito **Barcelona** e de forma semelhante juntar os conjuntos **L1** e **L2** em um único *dataset* chamado **Londres**, a fim de obter mais robustez na predição de preço.

A. Barcelona

TABLE V
RESULTADOS REFERENTES À CIDADE DE BARCELONA

Modelo	'day'	MSE	RMSE	R ²
Regressão Linear	Sim	0.0063	0.0792	0.5957
Regressão Linear	Não	0.0063	0.0792	0.5775
K-NN	Sim	0.0052	0.0724	0.6620
K-NN	Não	0.0030	0.0543	0.8095
XGBoost	Sim	0.0029	0.0542	0.8101
XGBoost	Não	0.0028	0.0526	0.8217

1) *Regressão Linear*: Os resultados da regressão linear foram idênticos, apesar da presença de regularização. Conforme apresentado na Tabela V, a inclusão da variável *day* resultou em um aumento nos valores de R² em comparação ao treinamento sem essa variável. Esse comportamento indica que a variável temporal contribui de forma positiva, porém limitada, para a capacidade explicativa do modelo linear.

Apesar do ganho observado com a inclusão de *day*, os valores de erro permanecem superiores aos obtidos pelos

modelos não lineares, reforçando que a regressão linear não é capaz de capturar adequadamente a complexidade do processo de formação de preços no contexto urbano de Barcelona.

2) *KNN*: O modelo KNN apresentou comportamento distinto em relação à inclusão da variável *day*. Como observado na Tabela V, quando essa feature é incluída, o modelo apresenta desempenho moderado. Entretanto, ao remover a variável *day*, observa-se um aumento expressivo no desempenho preditivo, acompanhado por uma redução significativa nos erros. A análise do gráfico de *Permutation Importance*, Figura 5, mostra que, no cenário com *day*, essa variável apresenta aumento negativo do erro quando permutada. Esse comportamento pode ser explicado pelo fato de que o algoritmo KNN baseia-se no cálculo de distâncias no espaço de características. Assim, a inclusão de uma variável irrelevante ou fracamente informativa, como *day*, pode introduzir ruído e distorcer a noção de similaridade entre observações. Em ambos os cenários, as variáveis *room_type_Private room* e *dist* permaneceram como as mais relevantes para o modelo.




Fig. 5. Permutation Importance - KNN (Barcelona)

3) *XGBoost*: O XGBoost apresentou o melhor desempenho entre os modelos avaliados para Barcelona. A diferença entre os dois cenários (com e sem a feature *day*) é pequena, como observado na Figura 32, caracterizando um ganho marginal associado à inclusão da variável temporal. A análise de importância das variáveis indica que *room_type_Private room* e *dist* são as *features* mais relevantes, independentemente da presença de *day*, evidenciando a robustez do modelo em relação a essa variável.

4) *Síntese dos resultados para Barcelona*: Em síntese, os resultados para Barcelona indicam que o XGBoost é o modelo mais adequado para a tarefa de predição de preços, pois apresenta o maior valor de R^2 e maior estabilidade em relação à inclusão da variável temporal *day*. O KNN demonstra elevada sensibilidade a essa variável, enquanto a regressão linear apresenta desempenho inferior em ambos os cenários. De forma consistente entre os modelos, as variáveis *room_type_Private room* e *dist* (ou *person_capacity*, no caso da regressão linear) destacam-se como os principais fatores explicativos, reforçando a importância do tipo de acomodação e da localização na dinâmica de preços em Barcelona.

B. Londres

1) *Regressão Linear*: Os resultados da regressão linear para o conjunto de dados de Londres, tanto na versão OLS quanto

TABLE VI
RESULTADOS REFERENTES À CIDADE DE LONDRES

Modelo	'day'	MSE	RMSE	R^2
Regressão Linear	Sim	0.0044	0.0662	0.6669
Regressão Linear	Não	0.0044	0.0662	0.6668
K-NN	Sim	0.0040	0.0636	0.6927
K-NN	Não	0.0017	0.0418	0.8671
XGBoost	Sim	0.0018	0.0427	0.8616
XGBoost	Não	0.0018	0.0420	0.8659

Ridge, foram idênticos. Conforme apresentado na Tabela VI, a inclusão da variável *day* não resultou em alterações relevantes no desempenho do modelo, e os valores de erro permanecem superiores aos observados nos modelos não lineares.

2) *KNN*: O modelo KNN apresentou comportamento semelhante ao observado para Barcelona, porém de forma ainda mais nítida. A inclusão da variável *day* resulta em uma queda considerável no desempenho do modelo, atuando de forma prejudicial ao modelo.

3) *XGBoost*: O XGBoost apresentou o melhor desempenho geral para o conjunto de dados de Londres. A diferença entre os dois cenários (com e sem a variável *day*) é mínima, caracterizando um impacto desprezível da variável temporal no desempenho do modelo.

4) *Síntese dos resultados para Londres*: Em síntese, conforme evidenciado na Tabela VI, os resultados para Londres indicam que o XGBoost apresenta o melhor desempenho e maior robustez entre os modelos avaliados. O KNN demonstra elevada sensibilidade à inclusão da variável *day*, com queda acentuada de desempenho quando essa feature está presente. Já a regressão linear apresenta desempenho inferior e praticamente inalterado com ou sem a variável temporal. De forma consistente entre os modelos, as *features* mais relevantes foram *room_type_Private room* e *attr_index*, enquanto variações temporais semanais exercem impacto limitado na predição de preços.

C. Modelos especialistas

1) *B1*: Para o subconjunto de dados de Barcelona considerando apenas dias úteis, foram treinados modelos XGBoost e KNN utilizando validação cruzada. O desempenho médio obtido foi de $R^2 \approx 0,72$ e $RMSE \approx 0,06$, indicando capacidade preditiva moderada nesse recorte temporal.

A análise da variabilidade entre os *folds* mostra diferenças entre as partições, com desvios padrão variando aproximadamente de 0,046 a 0,074, evidenciando heterogeneidade das partições, impactando o erro médio e reforçando a necessidade de validação cruzada.

2) *B2*: Para o subconjunto de dados de Barcelona considerando apenas finais de semana, o desempenho médio obtido foi de $R^2 \approx 0,63$ e $RMSE \approx 0,07$, indicando desempenho inferior ao observado no cenário de dias úteis.

A variabilidade entre os *folds*, com desvios padrão entre 0,062 e 0,073, indica estabilidade moderada entre as partições,

apesar do erro médio mais elevado, sugerindo maior complexidade nos padrões de preços aos finais de semana.

3) *L1*: Para o subconjunto de dados de Londres considerando apenas dias úteis, o desempenho médio obtido foi de $R^2 \approx 0,70$ e $RMSE \approx 0,07$, indicando boa capacidade preditiva nesse recorte temporal.

A análise da variabilidade entre os *folds*, com desvios padrão entre 0,030 a 0,045, indica maior estabilidade das partições em comparação a Barcelona, sugerindo padrões de preços mais consistentes nos dias úteis em Londres.

4) *L2*: Para o subconjunto de dados de Londres considerando apenas finais de semana, o desempenho médio obtido foi de $R^2 \approx 0,71$ e $RMSE \approx 0,06$, indicando desempenho semelhante ao observado para os dias úteis.

A variabilidade entre os *folds* apresentou desvios padrão baixos, variando aproximadamente de 0,025 a 0,036, indica alta estabilidade das partições, sugerindo padrões de preços consistentes em Londres entre dias úteis e finais de semana.

D. Modelo Global

Nesta etapa, foi adotado um modelo global, treinado conjuntamente com dados de Barcelona e Londres, com o objetivo de capturar padrões gerais de formação de preços comuns a diferentes mercados urbanos, permitindo a identificação de relações mais estáveis e menos dependentes de um contexto local específico.

A análise feita utilizando o algoritmo XGBoost, indica que a variável *room_type_Private room* é a mais relevante para o desempenho do modelo, evidenciando que o tipo de acomodação desempenha papel central na predição de preços. A importância relativa das variáveis pode ser observada no material suplementar, Figura 31.

Com o objetivo de avaliar de forma isolada a influência das variáveis relacionadas ao tipo de acomodação, foi conduzido um estudo de ablação. Essa metodologia consiste em treinar diferentes versões do mesmo modelo, mantendo inalterados o algoritmo XGBoost, variando apenas o conjunto de variáveis de entrada. Os resultados completos desse experimento são apresentados no material suplementar, Figura 33. Foram considerados três cenários: (i) um modelo contendo apenas a variável *room_type_Private*; (ii) um modelo contendo apenas *room_type_Shared room*, ambos em relação à categoria de referência *entire home*; (iii) um modelo baseline, no qual todas as variáveis relacionadas ao tipo de acomodação foram removidas, mantendo apenas as informações implícitas da categoria *entire home*.

Os resultados mostram que *room_type_Private* exerce influência significativa sobre a capacidade preditiva do modelo, alcançando $R^2 \approx 0.81$, o maior entre os cenários avaliados, o que evidencia uma dinâmica de preços distinta em relação à categoria *entire home*.

V. CONCLUSÃO E DISCUSSÃO

Neste trabalho, foram analisados os fatores determinantes da formação de preços de acomodações ofertadas na plataforma Airbnb nas cidades de Barcelona e Londres, com o objetivo

de auxiliar turistas na busca por opções de hospedagem com melhor custo-benefício. Para isso, foram avaliados diferentes modelos preditivos e estratégias de treinamento, considerando recortes por cidade, segmentações temporais e um modelo global.

Os resultados indicam que modelos não lineares, em especial o XGBoost, apresentam desempenho superior em todos os cenários analisados, evidenciando a existência de relações não lineares e interações complexas entre as variáveis explicativas. Em contraste, a regressão linear apresentou desempenho inferior, enquanto o modelo KNN mostrou elevada sensibilidade à inclusão da variável temporal *day*, indicando que essa feature não se mostrou relevante durante o treinamento e, ao ser incorporada, acabou prejudicando o desempenho preditivo do modelo.

Analisando os fatores determinantes foi revelado que o fator mais determinante para o preço é o tipo de acomodação, com destaque para *room_type_Private room*. Esse resultado indica que clientes que optam por quartos privativos devem esperar valores mais elevados em comparação à outras categorias. Além disso, variáveis associadas à localização, como a distância ao centro (*dist*) e o índice de atratividade turística (*attr_index*), mostraram-se altamente relevantes, sugerindo que acomodações mais centrais e situadas em regiões com maior concentração de atrações turísticas tendem a apresentar preços mais altos.

Diferenças entre as cidades também foram observadas. Barcelona apresentou maior variabilidade nos padrões de preços, especialmente nos finais de semana, enquanto Londres mostrou comportamento mais estável ao longo do tempo. Nesse contexto, destaca-se que o desempenho do XGBoost variou pouco entre os recortes de dias úteis e finais de semana, indicando que o modelo é robusto à inclusão de variáveis pouco informativas e capaz de capturar adequadamente relações não lineares e interações relevantes entre as features.

Em síntese, os resultados obtidos reforçam que o preço de acomodações do Airbnb é predominantemente determinado pelo tipo de acomodação e pela localização do imóvel. Esses achados fornecem subsídios relevantes para turistas na tomada de decisão de alugar um imóvel em Barcelona ou em Londres.

Para trabalhos futuros, sugere-se a incorporação de variáveis temporais mais detalhadas, como sazonalidade mensal, feriados e eventos locais, bem como a ampliação da análise para outras cidades, a fim de avaliar a generalização dos padrões identificados e aprimorar a capacidade preditiva dos modelos.

REFERÊNCIAS

- [1] Kaggle "Airbnb Prices in European Cities" [kaggle.com https://www.kaggle.com/datasets/thedevastator/airbnb-prices-in-european-cities](https://www.kaggle.com/datasets/thedevastator/airbnb-prices-in-european-cities) (accessed Dec. 5, 2025)
- [2] Airbtics "Best Airbnb Markets Europe in 2025" [airbtics.com https://airbtics.com/best-airbnb-markets-europe/](https://airbtics.com/best-airbnb-markets-europe/) (accessed Dec. 5, 2025)
- [3] K. Gyódi and L. Nawaro, "Determinants of Airbnb prices in European cities: A spatial econometrics approach (Supplementary Material)". Zenodo, Jan. 13, 2021. doi: 10.5281/zenodo.4446043.

VI. MATERIAL SUPLEMENTAR

TABLE VII
ESTATÍSTICAS DESCRITIVAS DE ATRIBUTOS NUMÉRICOS QUE NÃO SÃO
RELACIONADOS A DISTÂNCIA

	bedrooms		person capacity		guest satisfaction		cleanliness	
	Média	DP	Média	DP	Média	DP	Média	DP
B1	1.22	0.57	2.76	1.28	90.93	8.70	9.29	1.01
B2	1.09	0.58	2.45	0.96	91.33	8.50	9.30	1.02
L1	1.12	0.58	2.83	1.24	90.32	11.76	9.15	1.18
L2	1.13	0.58	2.86	1.25	90.92	11.29	9.19	1.15

TABLE VIII
ESTATÍSTICAS DESCRITIVAS DE ATRIBUTOS NUMÉRICOS DE
LOCALIZAÇÃO

	dist		metro dist		attr index		rest index	
	Média	DP	Média	DP	Média	DP	Média	DP
B1	2.12	1.35	0.43	0.24	464.37	268.32	877.66	461.29
B2	2.12	1.41	0.45	0.29	456.38	259.64	885.22	472.64
L1	5.33	2.72	0.99	1.26	296.47	172.44	629.79	389.95
L2	5.33	2.71	1.02	1.27	294.58	170.52	625.61	388.21




Fig. 6. Valores únicos do conjunto L1




Fig. 7. Valores únicos do conjunto L2




Fig. 8. Valores únicos do conjunto B1




Fig. 9. Valores únicos do conjunto B2




Fig. 10. Avaliação conjunta de outliers de B1




Fig. 11. Avaliação conjunta de outliers de B2




Fig. 12. Análise Multivariada de B1




Fig. 13. Análise Multivariada de B2




Fig. 14. Análise Multivariada de L1




Fig. 15. Análise Multivariada de L2




Fig. 16. Avaliação conjunta de outliers de L1




Fig. 17. Avaliação conjunta de outliers de L2




Fig. 18. Análise espacial de Barcelona




Fig. 21. Distribuição de *realSum* em L1




Fig. 19. Distribuição de *realSum* em B1




Fig. 20. Distribuição de *realSum* em B2




Fig. 22. Distribuição de *realSum* em L2




Fig. 23. Análise univariada de variáveis numéricas em relação a *realSum* em **B1**




Fig. 24. Análise univariada de variáveis categóricas em relação a *realSum* em **B1**




Fig. 25. Análise univariada de variáveis numéricas em relação a *realSum* em **B2**




Fig. 26. Análise univariada de variáveis categóricas em relação a *realSum* em B2




Fig. 27. Análise univariada de variáveis numéricas em relação a *realSum* em L1




Fig. 28. Análise univariada de variáveis categóricas em relação a *realSum* em L1




Fig. 29. Análise univariada de variáveis numéricas em relação a *realSum* em L2

Análise Bivariada com Log-RealSum




Fig. 30. Análise univariada de variáveis categóricas em relação *realSum* em L2




Fig. 31. Permutation Importance para o modelo XGBoost Barcelona




Fig. 32. Permutation Importance para o modelo XGBoost treinado de forma global




Fig. 33. Estudo ablação entre categorias de acomodação